

Identificador de Pacientes com Pneumonia a partir da imagem de raio-x

Priscila de Carvalho Otoni¹, Wellington Eugenio dos Santos², Ivan Carlos Alcântara de Oliveira³

{pri-decarvatoni@hotmail.com¹, wellgenio@outlook.com², ivancaoliveira@gmail.com³}

^{1, 2, 3}Universidade Cruzeiro do Sul (BRASIL)

RESUMO

Nos dias de hoje, a tecnologia está inserida em várias áreas do conhecimento, uma delas é a medicina, que usa a tecnologia, por exemplo, para auxiliar na identificação de diagnósticos de doenças como câncer de mama, tumores, fraturas, entre outras. Antes disso, em algumas doenças, como a pneumonia, as descobertas eram feitas pelo uso da radiação eletromagnética, conhecida como raio-x, na qual o diagnóstico é dado após uma análise visual feita pelo médico. Nessa linha, este artigo tem por finalidade apresentar um estudo de classificação de indivíduos diagnosticados com pneumonia ou não, por meio da análise de imagens de raio-x torácica feitos com o uso de técnicas de aprendizado de máquina, mais especificamente visão computacional. Para alcançar esse objetivo, foram realizadas pesquisas em bases de trabalhos acadêmicos para embasar os fundamentos deste artigo, além de obter e selecionar técnicas para automatizar esse processo e permitir a construção de um mapa conceitual relacionado a essa temática. A partir de uma base de dados de imagens de radiografias de tórax públicas e da seleção do algoritmo de Redes Neurais Convolucionais, foram realizados experimentos para treinamento e geração de um modelo preditivo que foi utilizado para o desenvolvimento de um sistema *web*, no qual ocorre a predição e visualização do diagnóstico ao inserir uma radiografia, indicando presença ou ausência de pneumonia com um percentual de assertividade.

Palavras Chaves: Redes Neurais Convolucionais, Radiografias, Classificação de Imagens, Sistema *Web*.

ABSTRACT

Nowadays, technology is inserted in several areas of knowledge, one of them is medicine, which uses technology, for example, to help identify diagnoses of diseases such as breast cancer,

tumors, fractures, among others. Prior to this, in some diseases, such as pneumonia, the findings were made by the use of electromagnetic radiation, known as x-ray, in which the diagnosis is made after a visual analysis by the doctor. In this line, this article aims to present a study of classification of individuals diagnosed with pneumonia or not, through the analysis of chest x-ray images made using machine learning techniques, more specifically computer vision. To achieve this goal, research was conducted in academic bases to support the foundations of this article, as well as obtaining and selecting techniques to automate this process and allow the construction of a conceptual map related to this theme. From a database of public chest X-ray images and the selection of the Convolutional Neural Networks algorithm, experiments were conducted to train and generate a predictive model that was used for the development of a web system, in which the prediction and visualization of the diagnosis by inserting a radiograph, indicating the presence or absence of pneumonia with an assertiveness percentage.

Keywords: *Convolutional Neural Networks, Radiographs, Image Classification, Web System.*

1. Introdução

A pneumonia pode ser categorizada como Pneumonia Adquirida na Comunidade (PAC) ou Pneumonia Adquirida em Hospital (SETHI, 2017). Ela é uma doença inflamatória que atinge os pulmões, sendo uma das principais causas de mortes de crianças menores de 5 anos e idosos (WORLD HEALTH ORGANIZATION, 2019). Essa doença se manifesta com mais frequência em países em desenvolvimento, como o Brasil (SOCIEDADE BRASILEIRA DE PEDIATRIA, 2018).

Em 1895, o alemão *Wilhelm Conrad Röntgen*, produziu a radiação eletromagnética nos comprimentos de onda, sendo chamada de raio-x (LUMMERICH, 2019) e, logo após, foi descoberto que ao usar o raio-x em uma frequência mais elevada, era possível destruir células cancerígenas (ARRUDA, 1996). E mesmo após tantos anos, essa técnica ainda é utilizada para obtenção de diagnósticos. O uso do raio-x está presente nos exames de fraturas ósseas, mamografias e, por meio dela, é possível identificar doenças pulmonares, como a pneumonia (PINHEIRO, 2019).

Até os dias atuais, a Organização Mundial de Saúde (OMS) recomenda o uso da radiografia de tórax para o diagnóstico de pneumonia, porém estudos mostram que tal diagnóstico tem uma forte dependência do observador, podendo ficar sujeito a fatores físicos e emocionais por parte do profissional da saúde (YOUNG; MARRIE, 1994).

Considerando o interesse dos autores nesse tema e no uso da tecnologia para simular a visão analítica humana para encontrar padrões de reconhecimento, este artigo tem por objetivo apresentar o estudo e implementação de um classificador de imagens de raio-x, como uma aplicação *web*, para prever se o diagnóstico de uma imagem é pneumonia ou não. Cabe ressaltar que o classificador não tem a pretensão de substituir o médico, mas funcionar como um auxiliar para seus diagnósticos.

Este artigo está organizado em seções, conforme descrição a seguir. Na seção 2, é apresentada a metodologia utilizada para elaboração deste trabalho. Um mapa conceitual, responsável por apresentar de forma sintetizada as estratégias usadas para a solução do problema, e alguns conceitos obtidos nas pesquisas bibliográficas são destacados na seção 3. Na seção 4, é detalhado o desenvolvimento da proposta de solução, bem como uma descrição da base de dados utilizada e os resultados da aplicação desenvolvida. Por fim, na seção 5, são destacadas as considerações finais e algumas sugestões de trabalhos futuros.

2. Metodologia

Para a realização deste trabalho, foram realizadas algumas etapas, sendo elas:

- ✓ Definição do tema de interesse;
- ✓ Pesquisa bibliográfica;
- ✓ Elaboração do mapa conceitual;
- ✓ Elaboração da revisão da literatura;
- ✓ Pesquisa e seleção da base de dados a ser tratada;
- ✓ Estudo e avaliação de trabalhos similares envolvendo as técnicas de classificação utilizadas e métricas de análise de erro;
- ✓ Análise das técnicas de classificação com o *Waikato Environment for Knowledge Analysis* (WEKA) para seleção da técnica com melhor assertividade;

- ✓ Aprofundamento dos estudos da técnica de classificação selecionada;
- ✓ Geração do modelo preditivo de classificação;
- ✓ Desenvolvimento de uma aplicação *web* que faz uso do modelo preditivo gerado;
- ✓ Realização dos testes na aplicação e análise dos resultados;

Ao definir o tema de interesse "identificador de pacientes com pneumonia a partir da imagem de raio-x ", foram feitas pesquisas bibliográficas para aprofundamento das técnicas que poderiam ser aplicadas e também houve pesquisas sobre o assunto pneumonia, por meio do qual foi possível perceber que, por estatísticas relativamente recentes, é uma das doenças que mais matam crianças menores de cinco anos (5 anos) e idosos no Brasil (SETHI, 2017). Por meio das pesquisas, também foi identificado que a tecnologia pode ser usada como ferramenta auxiliar na detecção dessa doença e assim auxiliar na detecção de diagnósticos e contribuir para diminuir o índice de mortalidade.

Para embasamento e melhor estruturação dos pontos abordados neste trabalho, foi desenvolvido um mapa conceitual, composto pelos pontos principais na abordagem de classificação de imagens. Logo após, foi elaborada a revisão da literatura composta pela exemplificação dos assuntos pneumonia, radiografia entre outros. E foi escolhida a base de dados pública disponibilizada pela comunidade de cientistas de dados *Kaggle* da empresa *Google* (MOONEY, 2018) para o desenvolvimento deste trabalho.

O levantamento das técnicas de classificação, se deu por meio das pesquisas de trabalhos acadêmicos e científicos similares, que tratavam do tema pneumonia, radiografias (raio-x) e tratamento de imagem.

A seleção da técnica de classificação e das métricas de análise de erro ocorreu tendo por base os resultados dos testes na ferramenta WEKA e, após isso, foram feitos estudos de aprofundamento na técnica de classificação selecionada, gerado o preditivo de classificação na linguagem *Python*, usando o suporte oferecido pelas bibliotecas de aprendizagem de máquina disponíveis e foram aplicados testes e validações, considerando as imagens selecionadas da base de dados.

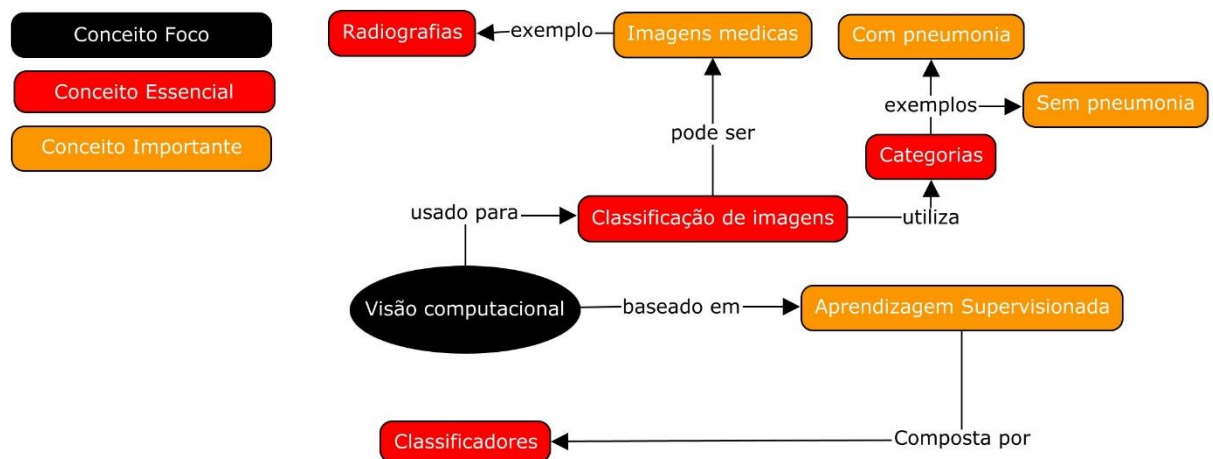
Após implementação do algoritmo, foi desenvolvida uma aplicação *web*, que usa o protocolo *Hypertext Transfer Protocol (HTTP)* para a comunicação de serviços (predição do algoritmo), baseada na definição da arquitetura, elaboração dos requisitos funcionais e não funcionais, além da modelagem UML e implementação em *Python*.

3. Revisão da literatura

3.1 Mapa conceitual do Classificador de Pneumonia

O mapa conceitual apresentado na Figura 1 ilustra a visão dos autores dos conceitos associados à temática deste trabalho. A partir dele, é possível perceber que a visão computacional é um dos fundamentos importantes na classificação de diagnóstico por meio de imagens.

Figura 1 - Mapa conceitual para classificação da pneumonia



Fonte: Elaborado pelos autores.

O mapa foi dividido em conceitos foco, essencial e importante, dos quais: foco, na cor preta, destaca-se a "visão computacional"; essencial, na cor vermelha, engloba radiografia e classificação de imagens; e importante, em laranja, envolve, por exemplo, imagens médicas e Aprendizagem Supervisionada.

3.2 Pneumonia

A pneumonia é uma doença causada pela penetração de agentes infecciosos, sendo eles, bactérias, fungos, alergias e vírus, no espaço alveolar (espaço de ventilação do pulmão) (SETHI, 2017). Esta infecção pode acontecer por baixa imunidade, inflamação crônica causada pelo tabagismo e alcoolismo.

Nos últimos anos, foram registrados 200 mil casos de óbitos por causa da pneumonia, sendo que 80% dos falecimentos foram de idosos acima de 65 anos e 18% de crianças menores de 5 anos. No Brasil, a pneumonia é a 4ª doença que mais mata (SOCIEDADE BRASILEIRA DE PNEUMONIA E TISIOLOGIA, 2018).

3.3 Radiografia

A Organização Mundial da Saúde (OMS) recomenda o uso de radiografia de tórax como sendo o melhor método disponível para o diagnóstico de pneumonia (WORLD HEALTH ORGANIZATION, 2001). Os equipamentos hospitalares passaram por um avanço significativo nos últimos anos, tornando o procedimento de captação de imagens radiográficas simples e rápido, mesmo em localidades fora dos grandes centros urbanos, viabilizando ainda mais o método indicado.

Apesar da recomendação da OMS, sobre uso da radiografia de tórax para o diagnóstico de pneumonia, estudos mostram que existe uma variabilidade considerável na interpretação por meio da observação dessas imagens por parte dos profissionais da saúde. Demonstrando que a leitura qualitativa da radiografia de tórax é altamente dependente do observador, sendo assim o diagnóstico fica sujeito a fatores como cansaço por parte do profissional da saúde e outros que influenciam a interpretação (YOUNG; MARRIE, 1994).

Nesse sentido, os avanços tecnológicos atuais que permitem uma interpretação de imagens por meio da visão computacional pode ser um mecanismo no auxílio desse tipo de diagnóstico.

Entre os vários benefícios que decorrem de uma interpretação mais precisa, pode-se citar a correção de erros que levam ao gasto inapropriado de medicamentos, gerando o desperdício de 15% dos 100 bilhões de dólares gastos com medicamentos (WANNMACHER, 2004).

3.4 Sistemas CAD

Devido a imprecisão na interpretação de imagens médicas, surge uma forte necessidade de um *software* que seja capaz de apoiar o diagnóstico. Esse tipo de sistema é conhecido como *Computer-Aided Diagnosis* (CAD), em uma tradução livre “sistema de auxílio a diagnóstico”.

CAD pode ser definido como um diagnóstico feito por um médico que leva em conta a saída do computador como uma segunda opinião (DOI, 1999). Dentre os sistemas de auxílio médico, tem-se os tipos:

- ✓ *Computer-Aided Detection* (CAdE): É usado para detectar e marcar elementos suspeitos nas imagens.

- ✓ *ComputerAided Diagnosis (CADx)*: É usado para realização do diagnóstico, gerando uma decisão, como positivo ou negativo para alguma enfermidade.

O desenvolvimento e implementação do sistema CAD, consiste em imitar a visão e percepção do analisador (especialista), procurando por aspectos na imagem para diagnosticar o paciente pela observação e, em seguida, tomar a decisão com base na experiência. De forma geral, a visão computacional, pode expressar esses passos por meio da extração de características e a classificação por aprendizagem supervisionada (SOUSA, 2013).

3.5 Visão computacional e *Machine learning*

A visão computacional tem a finalidade de imitar o olhar humano e é responsável por possibilitar que as máquinas enxerguem, ou seja, que elas consigam enxergar e compreender as coisas e objetos similar ao ser humano, envolvendo aspectos cognitivos da ciência da computação, tendo como base os conceitos da área de *Machine Learning*. Mitchell (1997) fornece o formalismo:

“A computer program is said to learn from experience E with respect to some class of tasks T and performance measure P , if its performance at tasks in T , as measured by P , improves with experience E .” (MITCHELL, 1997).

Em outras palavras, ele diz que um programa de computador aprende com a realização de uma tarefa, desde que se use uma função de avaliação para validar as soluções anteriores e propor novas melhorias.

Uma das vertentes na qual a visão computacional atua é a classificação com base no reconhecimento de padrões em imagens digitais. A classificação de imagens ocorre por meio da extração de características, identificação do objeto em estudo e associação a uma determinada classe (MITCHELL, 1997).

3.6 Aprendizado Supervisionado

O aprendizado supervisionado é o termo associado ao algoritmo treinado para identificação dos dados em um conjunto com classes pré-definidas. O seu funcionamento é da seguinte forma, a partir de um conjunto de dados com classes pré-definidas, o algoritmo analisa e descobre padrões existentes nos dados, gerando um modelo preditivo. Então, com base nesse modelo, a cada novo dado avaliado, é descoberto a qual classe ele pertence (MATOS, 2018).

3.7 Trabalhos Similares e Algoritmos de Classificação

Trabalhos similares a esta proposta foram utilizados como embaixadores para a escolha dos algoritmos de classificação e métricas de avaliação de erro.

Nos Quadros 1 e 2 estão relacionados alguns trabalhos publicados entre 2013 e 2019. Dentre eles, alguns abordam a descoberta de doenças pelo uso de imagens de radiografias, além de técnicas de reconhecimento e classificação. As métricas mais usadas para avaliação de resultados foram Acurácia, Especificidade, *Recall* e *Receiver Operating Characteristic (ROC Area)*.

Quadro 1 - Trabalhos Relacionados – parte 1

Trabalho	Algoritmo	Métricas
Costa (2019)	Redes Neurais Convolucionais (CNN)	Acurácia e <i>ROC Area</i>
Crespo e Hidalgo (2017)	Redes Neurais Convolucionais (CNN)	<i>Recall</i> , Especificidade e Acurácia
Dalvi (2018)	Redes Neurais Convolucionais (CNN)	Acurácia, <i>Recall</i> , Especificidade
Ferreira (2018)	<i>Random Forest</i>	Acurácia, <i>Recall</i> , Especificidade
Ferreira (2018)	<i>K - Nearest Neighbor (K-NN)</i>	Acurácia, <i>Recall</i> , Especificidade
Ferreira (2018)	Árvore de Decisão	Acurácia, <i>Recall</i> , Especificidade
Lopes (2017)	Redes Neurais Artificiais	Acurácia, Especificidade, <i>Recall</i> e Area Under the Curve (AUC)
Lopes (2017)	Redes Neurais Convolucionais (CNN)	Acurácia, Especificidade, <i>Recall</i> e AUC
Lopes (2017)	<i>Multiple Instance Learning</i>	Acurácia, Especificidade, <i>Recall</i> e AUC

Fonte: Elaborado pelos autores.

Com base nesses quadros, foram selecionados os algoritmos: *Naive Bayes* que tem como estratégia a abordagem estatística bayesiana para a classificação (SOUSA, 2013); *Support Vector Machine (SVM)* que usa o conceito de hiperplano para fazer a separação de classes (SOUSA, 2013); *K-Nearest Neighbor* que utiliza da distância euclidiana para efetuar a classificação (SOUSA, 2013); *Treej48* que emprega o conceito de árvore (estrutura de dados) na execução da classificação (FERREIRA, 2018); *RandomTree*, assim como *Treej48*, aplica o conceito de árvore porém com uma exceção, para cada divisão, apenas um subconjunto aleatório de atributos está disponível (FERREIRA, 2018); *Random Forest* que aplica múltiplas *RandomTree* (FERREIRA, 2018); *Multilayer Perceptron* que utiliza do conceito de rede neural (SOUSA, 2013); e Rede

Neural Convolucional (*CNN*) que também usa o conceito de rede neural adicionando as técnicas de convoluções (SOUSA, 2013).

Quadro 2 - Trabalhos Relacionados – parte 2

Trabalho	Algoritmo	Métricas
Lopes (2017)	Comitê de Classificadores	Acurácia, Especificidade, <i>Recall</i> e <i>AUC</i>
Moran (2019)	Redes Neurais Convolucionais (<i>CNN</i>)	Acurácia
Moreira (2017)	Redes Neurais Artificiais	Especificidade, <i>Recall</i> , Acurácia
Moreira (2017)	<i>Support Vector Machine (SVM)</i>	Especificidade, <i>Recall</i> , Acurácia
Santos et al. (2010)	Aprendizado Profundo	Acurácia, <i>Recall</i> e Precisão
Santos et al. (2010)	<i>Support Vector Machine (SVM)</i>	Acurácia, <i>Recall</i> e Precisão
Santos (2019)	Redes Neurais Convolucionais (<i>CNN</i>)	Acurácia
Silva et al. (2018)	Redes Neurais Convolucionais (<i>CNN</i>)	Acurácia
Souza (2013)	<i>Naive Bayes</i>	Acurácia e <i>ROC Area</i>
Souza (2013)	<i>K - Nearest Neighbor (K-NN)</i>	Acurácia e <i>ROC Area</i>
Souza (2013)	<i>Support Vector Machine (SVM)</i>	Acurácia e <i>ROC Area</i>
Souza (2013)	<i>MultiLayes Perceptron (MLP)</i>	Acurácia e <i>ROC Area</i>
Souza (2013)	Árvore de Decisão	Acurácia e <i>ROC Area</i>

Fonte: Elaborado pelos autores.

A *CNN* ou *ConvNet* é um tipo especial de rede neural multi-camada projetada para reconhecimento de padrão de imagens a partir dos seus pixels com baixo pré-processamento. Dentre as suas arquiteturas tem-se: *LeNet-5*, *AlexNet*, *ZFNet*, *GoogLeNet*, *VGGNet*, *ResNet* que diferem pelo número de camadas (DAS, 2017). Neste trabalho, foi selecionada a *LeNet*, introduzida na literatura pelo trabalho de Lecun (1998). A *LeNet* foi considerada uma das primeiras arquiteturas propostas, chamando atenção por possuir uma estrutura simples e pequena quando comparada com as arquiteturas mais atuais (LECUN, 1998).

A LeNet consiste em cinco camadas, sendo as duas primeiras camadas convolucionais de tamanho 5x5, passando pela função de ativação *Relu* e uma redução *Max Pooling* de tamanho 2x2. Em sequência, tem-se duas camadas totalmente conectadas, a primeira expandindo para 500 neurônios com a função de ativação *Relu* e a segunda reduzindo para 2 neurônios. Por fim, uma camada de ativação *Softmax* para efetivamente fazer a predição (LECUN, 1998).

4. Proposta, Desenvolvimento e Resultados

A partir de um estudo comparativo entre as diferentes técnicas de aprendizagem de máquina, este artigo tem como objetivo encontrar a mais assertiva no diagnóstico de crianças com pneumonia e desenvolver uma aplicação *web*.

Para isso, foi desenvolvida uma *API* que fornece o serviço de predição de pneumonia (usando a técnica de classificação LeNet) por meio de imagens digitais médicas (radiografias), usando o protocolo *HTTP*. A aplicação *web* faz uso desse serviço, permitindo o *upload* de radiografias e retornando à predição, dizendo se tem ou não pneumonia e o grau de confiança.

4.1 Base de Dados

A base de dados das imagens de raio-x utilizada neste projeto foi disponibilizada pela comunidade de cientistas de dados *Kaggle* da empresa *Google* (MOONEY, 2018).

Conforme Mooney (2018), essas imagens foram fornecidas pelo Centro Médico de Mulheres e Crianças de Guangzhou na China e referem-se a pacientes pediátricos com idades entre um e cinco anos.

Ainda segundo Mooney (2018), essas imagens foram selecionadas de acordo com a sua qualidade, para não impossibilitar o uso, e pela avaliação de três especialistas em pneumonia, que diagnosticaram aquelas que tinham pneumonia bacteriana ou viral e quais delas não tinham a doença.

Para este trabalho, essa base, composta por 5.857 imagens, foi dividida em três pastas: a primeira para treinamento, com 1.342 imagens normais e 3.875 de pneumonia; a segunda contendo as imagens para testes, apresenta 234 normais e 390 de pneumonia; e, por último, a terceira pasta para validação, composta por 8 imagens normais e 8 de pneumonia.

4.2 Algoritmos Seleccionados: Resultados dos Testes

Tendo por base os algoritmos seleccionados na seção 3.7, foi utilizada a ferramenta *WEKA* (versão 3.8) para testá-los e encontrar o mais assertivo. Ela é formada por uma coleção de algoritmos de *Machine Learning (ML)* para tarefas de mineração de dados, além de fornecer um conjunto de métricas para a validação dos algoritmos. Esse conjunto é composto pelas métricas *Precisão*, *Recall*, *ROC Area* e *Precision Recall Curve (PRC Area)*. Desenvolvida pela Universidade de Waikato na Nova Zelândia, essa ferramenta foi a escolhida por ser gratuita e apresentar uma boa documentação para estudo e aprendizado.


Nesses testes, foi utilizado o método de amostragem *r-fold cross-validation* que subdivide a base em *r* partições (*folds*) de tamanhos aproximadamente iguais dos quais, de forma cíclica, esse método utiliza 1 partição para testes e "*r-1*" para treinamento, cujo desempenho final é obtido pela média dos desempenhos observados sobre cada conjunto de teste.

Para iniciar os treinamentos com os algoritmos *Naive Bayes*, *Support Vector Machine (SVM)*, *K-Nearest Neighbor (K-NN)*, *Treej48*, *RandomTree*, *Random Forest* e *Multilayer Perceptron*, foi necessário fazer a extração dos recursos e características do *dataset* de imagens, ou seja, foi necessário transformar a matriz de imagens do *dataset* em um conjunto numérico para que os algoritmos pudessem interpreta-los e classifica-los, e essa extração se deu pela biblioteca *Image Classification Filter*. Porém, a técnica de *LeNet* disponibilizada pela biblioteca *The MNIST Dataset*, demonstrou não necessitar de recursos extratores.

Para a execução dos treinamentos e testes, foram consideradas as métricas *Precisão*, *Recall*, *ROC Area* e *PRC Area* devido a disponibilidade delas no *WEKA*. Como mencionado na anterior, na base de dados consta uma subdivisão de pastas contendo as imagens necessárias para os treinamentos, testes e validação do modelo preditivo, porém nas fases de treinamentos e testes feitos com *WEKA*, foi utilizado uma quantidade diferente das que estavam disponíveis, pela questão de performance da máquina utilizada.

Na Figura 2, é possível encontrar os resultados obtidos no treinamento com *10-fold cross validation* e a base de dados contendo 711 imagens de pneumonia e 1422 normais. Nesse treinamento, os melhores resultados de *Precisão*, *Recall*, *ROC Area* e *PRC Area* foram obtidos nos algoritmos *Random Forest*, *Naive Bayes* e *LeNet*.


Figura 2 - Treinamento dos Algoritmos



Fonte: Elaborado pelos autores.

E o teste realizado com o treinamento dos algoritmos, apresentados na Figura 3, contendo 390 imagens de pneumonia e 234 normais. Foi possível perceber que os algoritmos que obtiveram os melhores resultados, considerando as mesmas métricas de erro, foram *Naive Bayes*, *Random Forest* e *LeNet*.


Figura 3 - Teste dos Algoritmos



Fonte: Elaborado pelos autores.

Outro treinamento foi realizado com a base de dados balanceada, ou seja, 50% de imagens de pneumonia e 50% de imagens normais e *3-fold cross validation*. Na Figura 4, é possível perceber que os valores das métricas de Precisão, *Recall*, *ROC Area* e *PRC Area* melhoraram e os algoritmos que obtiveram melhores resultados foram *Naive Bayes*, *K-NN*, *Random Forest* e *LeNet*.


Figura 4 - Treinamento dos Algoritmos



Fonte: Elaborado pelos autores.

Outro teste foi realizado, após o modelo gerado no treinamento com os dados balanceados, conforme apresentado na Figura 5, contendo 390 imagens de pneumonia e 234 normais e *cross validation* com 3 *folds*, foi possível perceber que os algoritmos com melhores resultados foram *Naive Bayes*, *Random Forest* e *LeNet*. E, dentre os três, o algoritmo *LeNet* mostrou melhor métrica com 0,93 de *ROC Area* e *PRC Area*, além de 0,82 de precisão.

Figura 5 - Teste dos Algoritmos



Fonte: Elaborado pelos autores.

Como demonstra a Figura 5, a *LeNet* destaca-se na questão da performance, passando à frente da técnica *Random Forest* que, no processo de treinamento demonstrado na Figura 4, tinha alcançado os melhores resultados. A literatura mostra que isso ocorre porque a *LeNet* combina três ideias arquitetônicas, sendo elas a convolução, a subamostragem espacial e as camadas de neurónios densamente conectadas, para garantir um certo grau de escala de mudança e invariância da distorção, tornando-se mais flexível às novas imagens (LECUN, 1998).

Outra forma tangível de visualizar a eficiência, é a comparação dos erros entre as técnicas *Randon Forest* e *LeNet*, usando a Matriz de Confusão.

A Matriz de Confusão permite visualizar o desempenho de um algoritmo. Cada linha representa uma classe prevista, enquanto a cada coluna representa uma classe real. Todas as previsões corretas estão localizadas na diagonal da tabela e os erros são representados por valores fora da diagonal (CONGALTON, 1986).

Na Figura 6, é possível perceber que a classificação incorreta da *LeNet* ocorreu em 7 dos casos analisados, enquanto que no *Randon Forest* foram 42.

Figura 6 - Matriz de Confusão do processo de teste dos algoritmos *Randon Forest* e *LeNet*

	Pneumonia	Normal
Pneumonia	158	76
Normal	42	348

	Pneumonia	Normal
Pneumonia	105	129
Normal	7	383

Fonte: Elaborado pelos autores.

Baseados nos resultados obtidos nesta seção, o *LeNet* foi o algoritmo selecionado para geração do modelo preditivo a ser utilizado na implementação da aplicação deste projeto.

4.3 Implementação e Treinamento do Classificador

Considerando que o algoritmo *CNN* com a arquitetura *LeNet* foi o selecionado, foi realizada a sua implementação para treinamento da base e geração do modelo.

A implementação desse algoritmo foi realizada com a linguagem de programação *Python*, usando as bibliotecas *TensorFlow* na versão 1.14.0, *Keras* na versão 2.2.5 e *OpenCV Python* na versão 4.1.1.26, além de outras como *NumPy*.

Para o *LeNet* foram utilizados os seguintes parâmetros: i) 100 épocas de treino; ii) uma taxa de aprendizagem igual a 0.001. Também foram usados os métodos *EarlyStopping*, que tem o objetivo de treinar quando a função de perda não diminui, *ModelCheckpoint*, que salva a melhor versão do modelo a cada rodada de treinamento, e *ReduceLROnPlateau*, que diminui o valor da

taxa de aprendizagem, caso o modelo não evolua. Todos esses métodos são fornecidos pela biblioteca *Keras*.

Ainda na fase de treinamento, após 49 épocas o método *ReduceLROnPlateau*, foi chamado, melhorando a taxa de aprendizagem. Depois de 52 épocas, o método *EarlyStopping* foi chamado, parando o treinamento com uma acurácia de 87%.

Logo após os treinamentos, foi obtido uma precisão de 83% e *recall* de 93% para a classificação normal e 85% e 68% para pneumonia, tendo então uma média geral de 84% em ambas as métricas.

No Quadro 3, são mostradas as classificações feitas, por meio da matriz de confusão.

Quadro 3 - Resultados do processo de teste

	Normal	Pneumonia
Normal	363	75
Pneumonia	27	159

Fonte: Elaborado pelos autores.

O modelo preditivo gerado com essas métricas foi utilizado para a criação de um serviço *web* na forma de uma *Interface Program Application (API)*. Esse serviço é consumido pela aplicação desenvolvida.

4.4 A API: Detalhes de sua implementação

A API foi desenvolvida com a linguagem *Python* usando o *framework Flask* na versão 1.1.1. A comunicação com a aplicação é feita pelo uso do protocolo *HTTP*. Possuindo um único *endpoint (URL)* e aceitando apenas o método *POST* do protocolo *HTTP*. Ao tratar as imagens com *OpenCV Python* na versão 4.1.1.26 e *Keras* na versão 2.2.5, convertendo para uma matriz de *pixels*, retorna a classe predita e um percentual de confiança no formato *JavaScript Object Notation (JSON)*, resultado do algoritmo *LeNet*, previamente treinado, como mostrado na Figura 7.

A ideia por trás da elaboração da API é disponibilizar o serviço (predição de pneumonia com base em radiografias) a outros criadores de *software*.

Figura 7 - Exemplo de retorno da API

```
{
  "prediction": "PNEUMONIA",
  "probabilities": {
    "NORMAL": 0.028,
    "PNEUMONIA": 0.972
  },
  "success": true
}
```

Fonte: Elaborado pelos autores.

4.5 Aplicação: Arquitetura, Modelagem, Interface e Testes

A aplicação, denominada PneumoApp, é um *software web* que foi construído segundo a arquitetura *Model View Controller* (MVC) fazendo acesso a API para avaliação do diagnóstico da imagem.

Os requisitos funcionais e não funcionais, bem como a modelagem UML, resultados e testes da aplicação são resumidos a seguir.

Os requisitos funcionais são apresentados no Quadro 4.

Quadro 4 - Requisitos Funcionais (RF).

RF01 – Inserir imagem
O sistema deve permitir o <i>upload</i> de imagens.
RF02 – Exibir mensagem antes de enviar para avaliação
O sistema deve mostrar uma apresentação prévia da imagem que será enviada ao servidor.
RF03 – Predizer diagnóstico
O sistema deve prever se a radiografia possui ou não pneumonia.
RF04 – Exibir resultado da avaliação
O sistema deve apresentar a classificação da imagem e o grau de confiabilidade através de um gráfico medidor.

Fonte: Elaborado pelos autores.

No Quadro 5, são apresentados os requisitos não funcionais da aplicação.

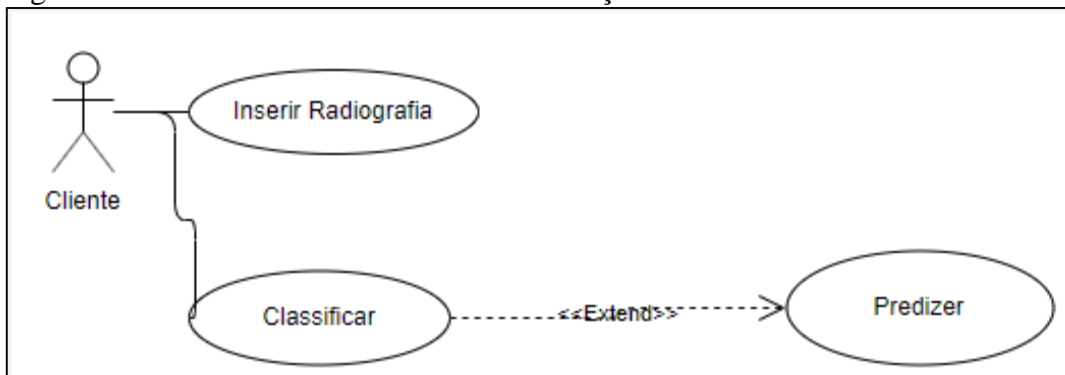
Quadro 5- Requisitos Não Funcionais (RNF).

RNF01 – Compatibilidade
O sistema deve ser compatível com os principais navegadores existentes, de forma a ser usado em qualquer sistema operacional.
RNF02 – Acessibilidade
O sistema deve possuir acessibilidade para dispositivos <i>Mobile e Desktop</i> .
RNF03 – Tempo de resposta
O sistema deve responder em um tempo igual ou inferior a um minuto.
RNF04 – Tolerante a falhas
Em caso de falhas com a API, o sistema deve mostrar mensagem de erro indicando a indisponibilidade do serviço.

Fonte: Elaborado pelos autores.

O diagrama de caso de uso é mostrado na Figura 8. Por meio dele, observa-se que o usuário introduz a imagem e clicando no botão classificar, a aplicação avalia o resultado.

Figura 8 - Caso de Uso - Sistema de Classificação



Fonte: Elaborado pelos autores.

A interface da aplicação foi criada por meio do *framework AngularJs*, na versão 1.7.7, podendo ser acessado tanto por um *Desktop* como *Mobile*.

Na Figura 9, é possível visualizar duas telas do sistema. A primeira é a tela de acesso com tudo normal, ou seja, quando há conexão com a Internet. A segunda indica serviço indisponível, caso a conexão seja perdida ou não esteja disponível.

Figura 9 - Tela de Início e Falha de Conexão do Sistema



Fonte: Elaborado pelos autores.

Na Figura 10, é possível visualizar dois testes. Um com a predição classificada como normal (imagem à esquerda) e o outro como pneumonia (imagem à direita).

Figura 10 - Tela com Predição do Classificador



Fonte: Elaborado pelos autores.

5. Considerações Finais e Trabalhos Futuros

A partir das pesquisas realizadas, foi possível perceber que a pneumonia é uma das doenças que apresenta maior índice de mortalidade entre crianças menores de 5 anos. Também que as análises dos diagnósticos da doença dependem de olhos humanos, ficando sujeito a erros, por depender do estado emocional, físico, psicológico e experiência do analisador.

Com o intuito de auxiliar o médico analisador, foi construída uma aplicação, nomeada PneuApp, que faz uso do algoritmo *CNN* com arquitetura *LeNet* para automatizar o diagnóstico de presença ou ausência de pneumonia. Esse algoritmo foi selecionado tendo por base trabalhos similares e testes realizados com o *WEKA* em conjunto com outros sete algoritmos. O *CNN* foi aquele que obteve melhor assertividade, segundo as métricas analisadas. A PneuApp foi construída como uma arquitetura *MVC* e faz acesso ao serviço disponibilizado por uma *API*, implementada com o modelo preditivo gerado com a *LeNet*.

Por meio dessa aplicação, é possível propor uma solução para a interpretação de imagens médicas (radiografias), servindo como uma segunda opinião para o diagnóstico de indivíduos com pneumonia, podendo ser usado até mesmo como um sistema de triagem.

Outras funcionalidades que podem ser agregados a PneuApp são:

- inclusão de um sistema de *login* para administradores e usuários (profissionais da medicina), viabilizando a impressão de diagnósticos.
- adição de uma retroalimentação do modelo com novas imagens, possibilitando o aprendizado contínuo do algoritmo de classificação.

- inserção de um mapa epidemiológico, promovendo uma visão geográfica da situação de pneumonia adquirida na comunidade, seja ela por cidade ou estado.

Referências

- ARRUDA, W. O. **Wilhelm Conrad Röntgen: 100 anos da descoberta dos raios X**. São Paulo: Scielo, 1996. Disponível em: < <http://www.scielo.br/pdf/anp/v54n3/27.pdf> >. Acesso em: 10 de outubro de 2019.
- BUCHPIGUEL, Dr. C. A. **A Evolução no Combate ao Câncer**. HCor, 2017. Disponível em < <https://www.hcor.com.br/materia/evolucao-no-combate-ao-cancer/> >. Acesso em: 15 de agosto de 2019.
- CONGALTON R. G. **Accuracy Assessment: A User's Perspective**. Berkeley: University of California, 1986.
- COSTA, A. C. **Deteção de Distorção Arquitetural Mamária em Mamografia Digital Utilizando Rede Neural Convolucional Profunda**. São Carlos: USP, 2019.
- CRESPO N., HIDALGA S. A. L. **Reconhecimento de Tumores Cerebrais Utilizando Redes Neurais Convolucionais**. Bagé: Universidade de Pampa, 2017.
- DALVI R. F. **Suporte a Deteção e Classificação de Câncer a Partir de Mamografias Digitalizadas e Redes Neurais Convolucionais**. Vitoria: Universidade Federal do Espírito Santo, 2018.
- DAS, S. **CNN Architectures: LeNet, AlexNet, VGG, GoogLeNet, ResNet and more... 2017**. Disponível em: <<https://medium.com/analytics-vidhya/cnns-architectures-lenet-alexnet-vgg-googlenet-resnet-and-more-666091488df5>>. Acesso em: 14 de novembro de 2019.
- DOI, K. et al. **Computer-aided Diagnosis in Radiology: Potential and Pitfalls**. Chicago: The University of Chicago, 1999.
- FERREIRA, M. M. **Aprendizado de Máquina Aplicado ao Suporte à Triagem de Pacientes Suspeitos de Tuberculose Pulmonar**. Rio de Janeiro: Universidade Federal do Rio de Janeiro, 2018.
- FILHO, A. M. S. **Artigo Engenharia de Software 3 - Requisitos Não Funcionais**. DevMedia, 2008. Disponível em: <<https://www.devmedia.com.br/artigo-engenharia-de-software-3-requisitos-nao-funcionais/9525>>. Acesso em: 20 de setembro de 2019.
- LECUN Y. **Gradient – Based Learning Applied to Document Recognition**. Proc. Of The IEEE, 1998. Disponível em: <<http://yann.lecun.com/exdb/publis/pdf/lecun-01a.pdf>>. Acesso em: 10 de setembro de 2019.
- LOPES U. K. **Redes neurais convolucionais aplicadas ao diagnóstico de tuberculose por meio de imagens radiológicas**. São Leopoldo: Universidade do Vale do Rio dos Sinos, 2017.
- LUMMERICH K. H. **1845: Nascia Wilhelm Conrad Röntgen, descobridor do raio X**. DW, 2019. Disponível em: <<https://www.dw.com/pt-br/1845-nascia-wilhelm-conrad-r%C3%B6ntgen-descobridor-do-raio-x/a-782500>>. Acesso em: 20 de outubro de 2019.
- MITCHELL T. M. **Machine Learning**. New York: McGraw-Hill Science, 1997.

MAYO M. **Image Classification Filter for WEKA**. Github, 2016. Disponível em: <<https://github.com/mmayo888/ImageFilter>>. Acesso em: 20 de setembro de 2019.

MATOS P. **Conceitos Fundamentais de Machine Learning**. Ciência e Dados, 2018. Disponível em: <<http://www.cienciaedados.com/conceitos-fundamentais-de-machine-learning/>>. Acesso em: 19 novembro 2019.

MOONEY P. **Chest X-Ray Images (Pneumonia)**. Kaggle, 2018. Disponível em: <<https://www.kaggle.com/paultimothymooney/chest-xray-pneumonia>>. Acesso em: 26 março 2019.

MORAN, M. B. H. **Metodologia para Localização de Nódulos Malignos da Tireoide a partir de Imagens Infravermelhas**. Niterói: Universidade Federal Fluminense, 2019.

MOREIRA, A. C. M. **Desenvolvimento e Aplicação de Ferramentas para o Pré-Processamento de Imagens de Ressonância Magnética Multi-Espectral**. Lisboa: Universidade Nova Lisboa, 2017.

PINHEIRO C. **Exame de raio-x: o que é, para que serve e quais os cuidados**. Saúde, 2019. Disponível em: <<https://saude.abril.com.br/medicina/exame-de-raio-x-o-que-e-para-que-serve-e-quais-os-cuidados/>>. Acesso em: 20 de outubro de 2019.

SANTOS, A. et al. **Uma Abordagem de Classificação de Imagens Dermatoscópicas Utilizando Aprendizado Profundo com Redes Neurais Convolucionais**. Teresina: Universidade Federal do Piauí, 2010.

SANTOS, M. K. **Redes Neurais na Classificação de Imagens da Membrana Timpânica**. Caxias do Sul: Universidade de Caxias do Sul, 2019.

SETHI, S. **Pneumonia Adquirida em Hospital**. Manual MSD, 2017. Disponível em: <<https://www.msdmanuals.com/pt-br/profissional/dist%C3%BArbios-pulmonares/pneumonia/vis%C3%A3o-geral-da-pneumonia>>. Acesso em: 20 de outubro de 2019.

SETHI, S. **Pneumonia Adquirida na Comunidade**. Manual MSD, 2017. Disponível em: <<https://www.msdmanuals.com/pt-br/profissional/dist%C3%BArbios-pulmonares/pneumonia/vis%C3%A3o-geral-da-pneumonia>>. Acesso em: 20 de outubro de 2019.

SILVA, I. R. R. et al. **Utilização de Redes Convolucionais Para Classificação e Diagnóstico da Doença de Alzheimer**. Recife: Universidade de Pernambuco, 2018.

SOCIEDADE Brasileira de Pneumologia e Tisiologia. **12 de novembro: Dia Mundial da Pneumonia**. Brasília, c2018. Disponível em: <<https://sbpt.org.br/portal/dia-mundial-pneumonia-2018/>>. Acesso em: 15 de setembro de 2019.

SOUSA, R. T. **Avaliação de Classificadores na Classificação de Radiografias de Tórax para o Diagnóstico de Pneumonia Infantil**. Goiás: Universidade Federal de Goiás, 2013.

UNITED Nations Children's Fund - UNICEF. **Pneumonia Claims the Lives of the World's Most Vulnerable Children**. New York, 2018. Disponível em: <<https://data.unicef.org/topic/child-health/pneumonia/>>. Acesso em: 15 de outubro de 2019.

WANNMACHER, L. **Uso Indiscriminado de Antibióticos e Resistência Microbiana: Uma Guerra Perdida. Uso racional de medicamentos**. Brasília: Organização Pan Americana de Saúde/Organização Mundial da Saúde, 2004.

WEKA 3. Version 3.8. Waikato: University Waikato, 2011. Disponível em: <<https://www.cs.waikato.ac.nz/ml/weka/index.html>>. Acesso em: 10 de setembro de 2019.

WEKA DeepLearning4j. ***The MNIST Dataset.*** Disponível em: <<https://deeplearning.cms.waikato.ac.nz/examples/classifying-mnist/>>. Acesso em: 10 de setembro de 2019.

WORLD Health Organization. ***Standardization of Interpretation of Chest Radiographs for the Diagnosis of Pneumonia in Children.*** Geneva: Department of Vaccines and Biologicals, 2001.

WORLD Health Organization. ***World Pneumonia Day.*** Geneva, 2016. Disponível em: <<https://www.who.int/life-course/news/events/world-pneumonia-day-2018/en/>>. Acesso em: 01 de outubro de 2019.

YOUNG, M.; MARRIE, TJ. ***Interobserver Variability in the Interpretation of chest Roentgenograms of Patients with Possible Pneumonia.*** Archives of internal medicine, Halifax: Department of Medicine, 1994.